




یادگیری آماری

الهام تبریزی
دانشگاه خوارزمی
پاییز ۱۴۰۴

مدلسازی



نمودارهای فروش در برابر هزینه‌های تبلیغات در تلویزیون، رادیو و روزنامه نشان داده شده‌اند و برای هر کدام یک خط رگرسیون خطی جداگانه برازش شده است.

سؤال این است که آیا می‌توان با تکیه بر این سه نوع هزینه‌ی تبلیغاتی، فروش را پیش‌بینی کرد؟ شاید بتوان با یک مدل جامع‌تر که فروش را تابعی از سه نوع هزینه‌ی تبلیغات در نظر می‌گیرد، عملکرد بهتری داشت:

$$\text{Sales} \approx f(\text{TV}, \text{Radio}, \text{Newspaper})$$

نمادها

در اینجا $Sales$ متغیر پاسخ یا همان متغیر هدفی است که قصد پیش‌بینی آن را داریم و به‌طور کلی آن را با Y نشان می‌دهیم. متغیر TV یک ویژگی، ورودی یا پیش‌بین است که آن را X_1 نام‌گذاری می‌کنیم. به‌همین ترتیب $Radio$ را X_2 و $Newspaper$ را X_3 می‌نامیم. مجموعه‌ی این ورودی‌ها را می‌توان به‌صورت یک بردار ورودی نوشت:

$$X = \begin{pmatrix} X_1 \\ X_2 \\ X_3 \end{pmatrix}.$$

مدل کلی ما به صورت زیر نوشته می‌شود:

$$Y = f(X) + \varepsilon$$

که در آن ε بیانگر خطاهای اندازه‌گیری و سایر ناهماهنگی‌ها بین مدل و واقعیت (متغیرهایی که روی پاسخ اثر داشته‌اند اما در مدل وارد نشده‌اند) است:


- قدرت اقتصادی منطقه (درآمد مردم، قدرت خرید)
- رقابت (حضور برندهای دیگر و تبلیغات آن‌ها)
- شهرت و کیفیت محصول
- فصل و زمان فروش (مثلاً فروش در تعطیلات بیشتر است)
- در دسترس بودن محصول (کمبود یا تأخیر در عرضه)
- خطاهای ثبت فروش یا نوسان‌های تصادفی بازار

یعنی می‌گوییم: فروش عمدتاً با تبلیغات در این سه رسانه توضیح داده می‌شود، اما عوامل دیگری هم هستند که ما اندازه‌گیری نکرده‌ایم یا وارد مدل نکرده‌ایم و همگی در بخش ε جمع شده‌اند.

تابع $f(X)$ چه فایده‌ای دارد؟

- اگر f را خوب برآورد کنیم (تخمین بزنیم)، می‌توانیم مقدار Y را برای نقاط جدیدی که فقط مقدار $X=x$ آن‌ها را می‌دانیم، پیش‌بینی کنیم.
- با داشتن f می‌توانیم تشخیص دهیم، کدام مؤلفه‌های بردار ورودی $X = (X_1, X_2, X_3)'$ در توضیح دادن Y نقش مهمی دارند و کدام یک بی‌اهمیت هستند. مثلاً سابقه کار (Seniority) و سال‌های تحصیل (Years of Education) معمولاً اثر زیادی روی درآمد (Income) دارند، اما وضعیت تأهل (Marital Status) معمولاً تأثیر معناداری ندارد.
- بسته به میزان پیچیدگی تابع f ، ممکن است بتوانیم بفهمیم هر مؤلفه‌ی X چگونه و با چه شکلی بر Y اثر می‌گذارد؛ مثلاً اثر خطی، غیرخطی، افزایشی یا کاهششی.

آیا یک $f(X)$ ایده آل وجود دارد؟



- در هر مقدار مشخص از X مثلاً $X = 4$ مقدار مناسب $f(X)$ چیست؟
- وقتی $X = 4$ باشد، ممکن است مقادیر مختلفی از Y مشاهده شود. بهترین مقدار برای تابع در این نقطه برابر است با

$$f(4) = E(Y|X = 4)$$

یعنی مقدار مورد انتظار (میانگین) Y به شرط اینکه $X = 4$ باشد.

- تابع $f(x) = E(Y|X = x)$ به عنوان تابع رگرسیون شناخته می شود و شکل ایده آل رابطه ی بین X و Y را بیان می کند.

تابع رگرسیون $f(X)$

- برای یک بردار ورودی نیز تعریف می شود. برای مثال، برای سه پیش بین داریم:

$$f(\mathbf{x}) = f(x_1, x_2, x_3) = E(Y|X_1 = x_1, X_2 = x_2, X_3 = x_3).$$

- این تابع بهینه ترین پیش بین Y از نظر کمینه کردن میانگین مربع خطا است. یعنی $E(Y|X = \mathbf{x})$ تابعی است که در هر نقطه‌ی $\mathbf{x}$ مقدار

$$E[(Y - g(X))^2 | X = \mathbf{x}]$$

را در میان تمام توابع ممکن g کمینه می کند.

- از آن جایی که ما همیشه تابع چگالی احتمال توام Y و X ها را نداریم، می توانیم f را در ساده ترین حالت ممکنه، یک تابع خطی در نظر بگیریم. به این نوع خاص از تابع رگرسیون، رگرسیون خطی می گویند.


مدل‌های پارامتری و ساختارمند

- مدل‌های پارامتری مجموعه‌ای از مدل‌ها هستند که در آن‌ها شکل کلی تابع $f(X)$ از قبل مشخص می‌شود و تنها تعداد محدودی پارامتر ناشناخته مانند $\beta_0, \beta_1, \dots, \beta_k$ باید با استفاده از داده‌ها برآورد شوند. این نوع مدل‌ها ساده، قابل تفسیر و از نظر محاسباتی، کارآمد هستند، اما ممکن است توانایی کافی برای نمایش روابط پیچیده را نداشته باشند. مدل خطی یک مثال مهم از مدل‌های پارامتری است:


$$f(X) = \beta_0 + \beta_1 X_1 + \dots + \beta_k X_k.$$


- این پارامترها با برازش مدل به داده‌های آموزشی برآورد می‌شوند.
- هرچند مدل خطی تقریباً هیچ‌وقت شکل واقعی رابطه‌ی $f(X)$ را دقیقاً توصیف نمی‌کند، اما در بسیاری از کاربردها یک تقریبی مفید، ساده و قابل تفسیر از تابع ناشناخته‌ی اصلی است.

اگرچه مدل خطی $\hat{f}_L(X) = \hat{\beta}_0 + \hat{\beta}_1 X_1$ لزوماً «مدل واقعی» نیست، ولی در این مثال روند کلی داده‌ها را درست تشخیص داده و برازش معقولی فراهم کرده است.




مدل درجه دوم $\hat{f}_Q(X) = \hat{\beta}_0 + \hat{\beta}_1 X_1 + \hat{\beta}_2 X_2$ تناسب کمی بهتر با داده‌ها دارد و می‌تواند تغییرات غیرخطی ساده را بهتر توضیح دهد.






نقاط قرمز داده‌هایی هستند که داده‌های آموزشی تلقی می‌شوند و f همان رویه‌ی آبی رنگ است.

$$\text{income} = f(\text{education}, \text{seniority}) + \epsilon$$



اگر بخواهیم f را با یک تابع خطی یا همان رگرسیون خطی تقریب بزنیم، از نمادهای زیر استفاده می‌کنیم:

$$\hat{f}_L(\text{education}, \text{seniority}) = \hat{\beta}_0 + \hat{\beta}_1 \times \text{education} + \hat{\beta}_2 \times \text{seniority}$$



اگر بخواهیم f را با یک تابع خطی یا همان رگرسیون خطی تقریب بزنیم، از نمادهای زیر استفاده می‌کنیم:

$$\hat{f}_L(\text{education}, \text{seniority}) = \hat{\beta}_0 + \hat{\beta}_1 \times \text{education} + \hat{\beta}_2 \times \text{seniority}$$

مثال. به داده‌های هزینه تبلیغات و میزان فروش توجه کنید و فرض کنید رابطه زیر بین میزان فروش و هزینه تبلیغات برقرار است:

$$Sales_i = \beta_0 + \beta_1 TV_i + \beta_2 Radio_i + \beta_3 Newspaper_i + \varepsilon_i,$$

به طوری که در آن ε_i ها به ازای $i = 1, 2, \dots, N$ دارای توزیع نرمال با میانگین ۰ و واریانس σ^2 هستند. بنابراین، ثابت‌های نامعلوم در این مدل خطی یا همان پارامترها، $\beta_0, \beta_1, \beta_2, \beta_3$ و σ^2 است.

- به راحتی در آمار ریاضی می‌توان دید که وقتی توزیع متغیر تصادفی پاسخ ($Sales_i$) مد نظر قرار داده می‌شود، این متغیر دارای توزیع نرمال با میانگین

$$E(Y|X_1 = x_1, X_2 = x_2, X_3 = x_3) = \beta_0 + \beta_1 TV_i + \beta_2 Radio_i + \beta_3 Newspaper_i$$

و واریانس σ^2 است.

- این پارامترها باید توسط ۲۰۰ نمونه که گرفته شده است، برآورد شوند.
- راه برآوردی که ما در این کلاس یاد گرفته‌ایم؟؟؟؟؟؟

به مطالبی که روی تخته نوشته می شود و کدهای R
با دقت
توجه کنید.