

یادگیری آماری

الهام تبریزی
دانشگاه خوارزمی
پاییز ۱۴۰۴

مثال (پیش‌بینی بیماری فشار خون).

در یک تحقیق که برای بررسی برخی عوامل خطر بیماری پرفشاری خون انجام شده است، تعداد ۱۰۰ نفر مورد بررسی قرار گرفته‌اند که داده‌های مربوط به آنها در فایل HNT.xls آمده است. مشخصات متغیرهای به صورت زیر می‌باشد:

سن	AGE	مصرف سیگار	SMOKING
جنس	SEX		
مرد	1	خیر	0
زن	2	بله	1
سطح تحصیلات	EDUCATION	وزن (کیلوگرم)	WEIGHT
بی سواد	0	قد (سانتی متر)	HEIGHT
ابتدایی	1	وضعیت بیماری پرفشاری خون	HTN
راهنمایی	2	سالم	0
دبیرستان و دیپلم	3	بیمار	1
دانشگاهی	4		
ورزش	EXRCS	نمایه توده بدن	BMI
خیر	0	وزن طبیعی	<25
بله	1	اضافه وزن	25-29.99
		چاق	>=30

توضیح اینکه نمایه توده بدن (BMI) از حاصل تقسیم وزن (برحسب کیلوگرم) بر مجذور قد (برحسب متر مربع) به دست می آید.

1. با در نظر گرفتن متغیر وضعیت بیماری پرفشاری خون به عنوان متغیر هدف و سایر متغیرها به عنوان ویژگی، مدل مناسب برای تحلیل داده‌ها چیست؟

2. احتمال ابتلا به بیماری پرفشاری خون برای یک مرد ۵۹ ساله سیگاری چاق که ورزش می‌کند را محاسبه نمایید.

مدل رگرسیون لجستیک

وقتی متغیر پاسخ Y دو حالتی (باینری) باشد، مثل:

- خرید/عدم خرید محصول
 - موفقیت/شکست یک تبلیغات
 - ابتلا/عدم ابتلا به بیماری
 - بنابراین Y از توزیع برنولی تبعیت می کند:
- $$Y_i | X_i = \mathbf{x}_i \sim \text{Bernoulli}(\pi_i(\mathbf{x}_i)),$$
- توجه کنید که $\pi_i(\mathbf{x}_i) = P(Y_i=1 | X_i = \mathbf{x}_i)$
 - هدف مدل: پیش بینی احتمال رخداد π_i با توجه به ویژگی های X

مدل رگرسیون لجستیک

۱. آشنایی با بخت (Odds)

مفهوم شهودی:

- در «احتمال» سوال این است که: از میان همه‌ی افراد، چه درصدی یا چند نفر دچار بیماری (موفقیت یا همان $Y = 1$) می‌شوند؟
- در «بخت» سوال این است که: به ازای هر چند فرد دچار بیماری، چند فرد سالم در جامعه داریم؟

تعریف رسمی بخت:

$$Odds = \frac{\text{احتمال موفقیت}}{\text{احتمال شکست}} = \frac{P(Y_i=1|X_i=x_i)}{1-P(Y_i=1|X_i=x_i)} = \frac{\pi_i(x_i)}{1-\pi_i(x_i)}.$$

آشنایی با بخت (Odds)

مثال (ابتلا به پرفشاری خون)

اگر احتمال ابتلا $0/2$ باشد، یعنی از هر ۱۰۰ نفر ۲۰ نفر مبتلا داریم. بخت نیز برابر با $\frac{0/2}{0/8}$ یعنی $0/25$ است:

به ازای هر ۱ بیمار، ۴ فرد سالم در جامعه داریم. بخت برد در این بازی ۱ به ۴ است.

چرا بخت در رگرسیون لجستیک مهم است؟

- در لجستیک نمی توان احتمال را مستقیماً مدل سازی کرد (زیرا باید بین ۰ و ۱ بماند) اما بخت می تواند هر مقداری بین صفر تا $+\infty$ بگیرد.
- با گرفتن لگاریتم از بخت (تابع لوجیت)، مقدار بخت به عددی بین $-\infty$ تا $+\infty$ تبدیل می شود. بنابراین می تواند به صورت یک ترکیب خطی از ویژگی ها مدل سازی شود.

مدل رگرسیون لجستیک

رابطه بین k متغیر تبیینی یا همان ویژگی‌ها و پارامتر (احتمال رخداد) π از طریق تابع ربط لوجیت به صورت زیر مدل‌سازی می‌شود:

$$\text{logit}(\pi_i) = \log\left(\frac{\pi_i}{1-\pi_i}\right) = \boldsymbol{\beta}'\mathbf{x}_i, \quad i = 1, 2, \dots, n,$$

که در آن $\boldsymbol{\beta}$ بردار ضرایب ثابت و $\mathbf{x}_i$ بردار ویژگی‌ها برای واحد i ام است.

تذکر: همانند رگرسیون خطی، هدف مدل کردن رابطه بین متغیرهای توضیحی و پاسخ است، اما خروجی مدل، احتمال رخداد است، نه مقدار عددی مستقیم برای متغیر پاسخ.

تابع درستنمایی مدل لجستیک

برای n مشاهده مستقل (y_i, x_i)

$$L(\boldsymbol{\beta}) = \prod_{i=1}^n \pi_i^{y_i} (1 - \pi_i)^{1-y_i},$$

که در آن

$$\pi_i = \frac{e^{\boldsymbol{\beta}' x_i}}{1 + e^{\boldsymbol{\beta}' x_i}}.$$

ما با ماکزیمم کردن لگاریتم تابع درستنمایی $l(\boldsymbol{\beta})$ ، پارامترهای $\boldsymbol{\beta}$ را برآورد می‌کنیم.

نقشه راه این جلسه

- به مثال اول کلاس برگردید.
- کدهای R را ابتدا به کمک تابعی مثل glm بنویسید که بتوانیم در رابطه با تفسیر پارامترهای صحبت کنیم.
- بعد از برازش مدل به کمک توابع از پیش تعریف شده در R ، خودمان تابعی می‌نویسیم که برآوردهای mle پارامترهای مدل را محاسبه کند و با خروجی تابع glm مقایسه می‌کنیم که یکسان باشند.
- به آشنایی با تفسیر پارامترها می‌پردازیم

باز کردن داده‌ها در R و آماده‌سازی آن‌ها

```
> d = read_excel("E:\\1404-1405-1\\Math Software\\datasets\\HNT.xlsx", col_names = TRUE)
> head(d)
# A tibble: 6 × 8
  AGE    SEX EDUCATION EXRCS SMOKING WEIGHT HEIGHT HTN
  <dbl> <dbl>    <dbl> <dbl>   <dbl>   <dbl>   <dbl> <dbl>
1    35     1         0     0       1      89    166     1
2    35     1         3     0       1      64    163     0
3    35     1         2     1       0      79    159     0
4    35     1         3     1       0      59    171     0
5    35     1         3     0       0      67    178     0
6    35     2         1     1       0      48    157     0

> % attach(d)
Error: unexpected input in "% attach(d)"
>
> SEX = factor(SEX)
> EDUCATION = factor(EDUCATION)
> EXRCS = factor(EXRCS)
> SMOKING = factor(SMOKING)
> bmi = WEIGHT/((HEIGHT/100)^2)
> BMI <- cut(bmi,
+           breaks = c(-Inf, 25, 30, Inf),
+           labels = c(1, 2, 3),
+           right = FALSE)
```

برازش در R با کمک تابع glm

```
> m = glm(HTN~SMOKING+bmi ,family = binomial(link = "logit"))  
> #For every X cases, how many non-cases do we have? Odds  
> m
```

```
Call: glm(formula = HTN ~ SMOKING + bmi, family = binomial(link = "logit"))
```

Coefficients:

(Intercept)	SMOKING1	bmi
-7.783	1.579	0.266

```
Degrees of Freedom: 99 Total (i.e. Null); 97 Residual
```

```
Null Deviance: 138.3
```

```
Residual Deviance: 101.7 AIC: 107.7
```

$$\text{logit}(\pi_i) = \log\left(\frac{\pi_i}{1-\pi_i}\right) = -7.78 + 1.57\text{Smoking}_i + 0.26 \text{bmi}_i,$$

که در آن $i = 1, 2, \dots, 100$ و π_i احتمال ابتلا به بیماری پرفشاری خون

برای بیمار i ام است: $\pi_i = P(HNT_i=1|\text{Smoking}_i, \text{bmi}_i)$

یافتن برآوردگرهای MLE

```
> rm(list=ls())
> d = read_xlsx("E:\\1404-1405-1\\Math SoftWare\\datasets\\HNT.xlsx",col_names = TRUE)
> bmi = WEIGHT/((HEIGHT/100)^2)
>
> mylogit <- function(p){
+ pi = plogis(p[1]+p[2]*SMOKING+p[3]*bmi)
+ -sum(dbinom(HTN,1,pi,log = TRUE))
+ }
>
> p0 = c(mean(HTN)/(1-mean(HTN)),0,0)
> nlminb(p0,mylogit,lower = rep(-Inf,3),upper = rep(Inf,3))
$par
[1] -7.7827738  1.5790823  0.2660282

$objective
[1] 50.83338

$convergence
[1] 0

$iterations
[1] 10

$evaluations
function gradient
      17      42

$message
[1] "relative convergence (4)"
```

تفسیر پارامترها در رگرسیون لجستیک

تفسیر ضرایب ویژگی‌های کمی:

برای تفسیر ضریب یک متغیر کمی مانند bmi باید ضریب (β_2) آن تنها شود:

$$\text{logit}(P(HNT_i=1|Smoking_i = s, bmi_i = x + 1)) -$$

$$\text{logit}(P(HNT_i=1|Smoking_i = s, bmi_i = x)) =$$

$$\beta_0 + \beta_1 s + \beta_2(x + 1) - \beta_0 + \beta_1 s + \beta_2 x =$$

$$\beta_2.$$

بنابراین، از آن جایی که

$$\text{logit}(P(HNT_i=1|Smoking_i = s, bmi_i = x)) =$$

$$\log(Odds(Smoking_i = s, bmi_i = x)),$$

نتیجه می‌شود:

تفسیر پارامترها در رگرسیون لجستیک

$$\log \left(\frac{Odds(Smoking_i = s, bmi_i = x + 1)}{Odds(Smoking_i = s, bmi_i = x)} \right) = \beta_2 \quad \Rightarrow$$

$$\frac{Odds(Smoking_i = s, bmi_i = x + 1)}{Odds(Smoking_i = s, bmi_i = x)} = e^{\beta_2}.$$

• هر ۱ واحد افزایش در **bmi** به شرط ثابت بودن سایر ویژگی‌ها باعث

می‌شود بخت پیروزی یا بخت ابتلا به بیماری e^{β_2} برابر شود.

• اگر دو بیمار با شرایط مشابه در مورد وضعیت سیگار کشیدن داشته باشیم،

بیماری که یک واحد **bmi** بیشتر دارد بخت ابتلا به بیماری پرفشاری خون برای ایشان $1.3 = e^{0.26}$ برابر بیمار دیگر است.

• با هر ۱ واحد افزایش در **bmi**، بخت ابتلا به پرفشاری خون حدود ۳۰٪ بیشتر می‌شود.

تفسیر پارامترها در رگرسیون لجستیک

تفسیر ضرایب ویژگی‌های کیفی

الف) ۲ سطحی (۰-۱)

برای تفسیر ضریب یک متغیر کمی مانند bmi باید ضریب (β_2) آن تنها شود:

$$\frac{Odds(Smoking_i = 1, bmi_i = x)}{Odds(Smoking_i = 0, bmi_i = x)} = e^{\beta_1}.$$

- **بخت پیروزی وقتی فردی سیگاری است، به شرط ثابت بودن سایر ویژگی‌ها e^{β_1} برابر یک فرد غیرسیگاری است.**
- اگر دو بیمار با bmi یکسان داشته باشیم، بیماری که سیگاری است، بخت ابتلا به بیماری پرفشاری خون برای ایشان $e^{1.57} = 4.8$ برابر بیمار غیرسیگاری است.
- سیگار کشیدن بخت ابتلا به پرفشاری خون را تقریباً ۵ برابر می‌کند.

تفسیر پارامترها در رگرسیون لجستیک

تفسیر ضرایب ویژگی‌های کیفی

ب) چند سطحی

```
> m2 = glm(HTN~SMOKING+BMI+EDUCATION+SEX+EXRCS ,family = binomial(link = "logit"))  
> m2
```

```
Call: glm(formula = HTN ~ SMOKING + BMI + EDUCATION + SEX + EXRCS,  
          family = binomial(link = "logit"))
```

Coefficients:

(Intercept)	SMOKING1	BMI2	BMI3	EDUCATION1	EDUCATION2	EDUCATION3	EDUCATION4
-2.8153	2.7216	2.5070	2.8741	-0.1551	0.3721	-2.3213	-1.7553
SEX2	EXRCS1						
2.4113	-1.5232						

Degrees of Freedom: 99 Total (i.e. Null); 90 Residual

Null Deviance: 138.3

Residual Deviance: 66.26 AIC: 86.26

$$\text{logit}(\pi_i) = -2.8 + 2.7\text{Smoking}_i + 2.5\text{BMI2}_i + 2.8\text{BMI3}_i - 0.1\text{EDU1}_i + \\ 0.37\text{EDU2}_i - 2.3\text{EDU3}_i - 1.7\text{EDU4}_i + 2.4\text{SEX2}_i - 1.5\text{EXRCS1}_i.$$

تفسیر پارامترها در رگرسیون لجستیک

تفسیر ضرایب ویژگی‌های کیفی

(ب) چند سطحی

وقتی یک متغیر کیفی چند سطحی مانند «تحصیلات» وارد مدل می‌شود، مدل نمی‌تواند آن‌ها را مستقیماً به صورت عددی مقایسه کند.

- بنابراین هر سطح به یک متغیر صفر/یک (*dummy*) تبدیل می‌شود.
- یکی از سطوح به عنوان رده‌ی مرجع انتخاب می‌شود.
- رده‌ی مرجع همان سطحی است که سایر سطوح نسبت به آن مقایسه می‌شوند و بنابراین بهتر است رایج‌ترین رده، به عنوان رده مرجع در نظر گرفته شود.

تفسیر پارامترها در رگرسیون لجستیک

مثال: سطح تحصیلات

- در خروجی تابع glm ، کوچک‌ترین سطح، یعنی بی‌سواد، به صورت پیش فرض، به عنوان رده مرجع در نظر گرفته می‌شود.
- برای مثال چون $\beta_{EDU2} = 0.3$ و $e^{0.37} = 1.4$ ، می‌توان گفت افراد با تحصیلات راهنمایی نسبت به افراد بی‌سواد حدود ۱.۴ برابر بخت بیشتری برای ابتلا دارند.
- $\beta_{EDU3} = -2.3$ و $e^{-2.3} = 0.1$ ، می‌توان گفت افراد دارای تحصیلات دبیرستان نسبت به بی‌سوادها حدود ۹۰٪ بخت کمتری برای ابتلا دارند.

تفسیر پارامترها در رگرسیون لجستیک

تفسیر سایر متغیرها و سطوح شان را شما به من بگویید!