

یادگیری آماری

الهام تبریزی
دانشگاه خوارزمی
پاییز ۱۴۰۴

مدل رگرسیون پروبیت

دقیقا مانند مدل رگرسیون لجستیک، وقتی متغیر پاسخ Y دو حالتی (باینری) باشد.

چه زمانی از رگرسیون پروبیت استفاده کنیم؟

۱. وقتی پشت خروجی صفر/یک، یک «عامل پنهان» وجود دارد:

گاهی نتیجه نهایی (۰ یا ۱ شدن) به صورت ناگهانی دیده می شود، اما در واقع یک مقدار پنهان درونی وجود دارد که وقتی از یک حد رد می شود، نتیجه ۱ می شود.

چه زمانی از رگرسیون پروبیت استفاده کنیم؟

مثال: «تمایل واقعی» یک مشتری برای خرید یک محصول عددی است، اما شما فقط می‌بینید خریده (۱) یا نخریده (۰).

• اگر این تمایل پنهان از یک حد بالاتر برود $\rightarrow$ خرید انجام می‌شود.

وقتی فکر می‌کنیم رفتار خروجی بر اساس عبور یک مقدار پنهان از «آستانه» شکل می‌گیرد، پروبیت گزینه بهتری است.

$$Y_i = \begin{cases} 1, & Y_i^* > \theta \\ 0, & Y_i^* < \theta \end{cases}$$

در مثال فوق، Y_i^* متغیری پیوسته است و نشانگر تمایل واقعی مشتری برای خرید.

چه زمانی از رگرسیون پروبیت استفاده کنیم؟

۲. وقتی فرض می‌کنیم خطا یا نوسان تصمیم‌ها «نرمال» است.

تابع پروبیت از توزیع نرمال ساخته شده است. یعنی فرض می‌کنیم عدم قطعیت تصمیم‌گیری یا نوسان رفتار افراد شبیه نرمال است.

مثال: افراد ممکن است در مورد خرید، شرکت در رأی‌گیری، انتخاب محصول یا ریسک‌پذیری، رفتاری داشته باشند که شبیه "پخش نرمال" حول یک مقدار میانی است.

- در این حالت پروبیت طبیعی‌تر و واقعی‌تر رفتار را مدل می‌کند.

اگر فکر کنید «رفتار افراد» حول یک حدّ وسط نرمال پخش شده است، پروبیت مناسب‌تر است.

چه زمانی از رگرسیون پرویت استفاده کنیم؟

۳. جاهایی که پرویت به طور سنتی انتخاب استاندارد است.

- مدل‌های انتخاب در اقتصاد (بخرد یا نخرد)
- مدل تمایل پنهان به پرداخت
- تصمیم‌گیری‌های انسانی که تدریجی و نه ناگهانی تغییر می‌کنند:
 - در بسیاری از رفتارهای انسان، افراد:
 - به یکباره تصمیم نمی‌گیرند
 - ناگهان از ۰ به ۱ نمی‌پرند
 - بلکه «تمایل»، «باور»، «رضایت»، «ترس»، «میل»، «آمادگی ذهنی» یا «احساس نیاز» به تدریج و مانند یک متغیر پیوسته بالا و پایین می‌شود.

چه زمانی از رگرسيون پرويت استفاده كنيم؟

مثال شفاف:

- تمایل يك فرد به خريد يك محصول
- ابتدا كم است
- با ديدن تبليغ، تجربه دوست، افزايش نياز، يا ارزان شدن کالا به تدريج زياد يا كم مي شود
- وقتی از يك حد خاص گذشت، فرد تصميم مي گيرد بخرد (۱)
- اگر زير آن حد بماند، نمي خرد (۰)

• مطالعات داروسازی که واكنش ها نرمال هستند:

- بدن انسان نسبت به دوز دارو به تدريج واكنش نشان مي دهد
- شدت اثر دارو به صورت نرمال گونه بين افراد پخش است
(بعضی افراد حساس تر، بعضی مقاوم تر)

اما خروجی نهایی که اندازه گیری می شود دوتایی است. دارو اثر کرد (۱) یا نکرد (۰). پس واقعیت این است که شدت واكنش دارویی يك متغير پنهان پیوسته است.

معرفی مدل رگرسیون پروبیت

مدل رگرسیون پروبیت، مانند لجستیک، زمانی استفاده می شود که متغیر پاسخ دو حالتی (۰ یا ۱) باشد. در این مدل نیز فرض می کنیم:

$$Y_i | X_i = x_i \sim \text{Bernoulli}(\pi_i(x_i)),$$

که در آن $\pi_i(x_i) = P(Y_i=1 | X_i = x_i)$

- هدف مدل: پیش بینی احتمال رخداد π_i با توجه به ویژگی های X

ایده متغیر پنهان (Latent Variable) در پروبیت

پروبیت بر این فرض استوار است که پشت خروجی ۰ یا ۱، یک مقدار پنهان پیوسته قرار دارد:

$$Y_i^* = \beta_1 x_{i1} + \dots + \beta_k x_{ik} + \varepsilon_i,$$

که در آن Y_i^* متغیر پنهان فرد i ام و $\varepsilon_i \sim N(0,1)$ جملات خطای مستقل از یکدیگر هستند. توجه کنید که مدل فوق بدون عرض از مبدا است. خروجی مشاهده شده یا متغیر پاسخ چنین تعریف می شود:

$$Y_i = \begin{cases} 1, & Y_i^* > \theta \\ 0, & Y_i^* < \theta \end{cases}$$

تابع ربط پروبیت – مدل رگرسیون پروبیت

رابطه بین k متغیر تبیینی یا همان ویژگی‌ها و پارامتر (احتمال رخداد) π از طریق تابع ربط پروبیت به صورت زیر مدل‌سازی می‌شود:

$$\pi_i = \Phi(\beta_0 + \beta_1 x_{i1} + \dots + \beta_k x_{ik}), \quad i = 1, 2, \dots, n,$$

که در آن، $\Phi(\cdot)$ تابع توزیع تجمعی نرمال استاندارد و $\beta_0 = -\theta$ است.

برای علاقه‌مندان: 😊

$$\begin{aligned} \pi_i &= P(Y_i=1|X_i = \mathbf{x}_i) = P(Y_i^* > \theta | X_i = \mathbf{x}_i) \\ &= P(\beta_1 x_{i1} + \dots + \beta_k x_{ik} + \varepsilon_i > \theta | X_i = \mathbf{x}_i) \\ &= P(\varepsilon_i > \theta - \beta_1 x_{i1} - \dots - \beta_k x_{ik} | X_i = \mathbf{x}_i) \\ &= P(\varepsilon_i \leq -\theta + \beta_1 x_{i1} + \dots + \beta_k x_{ik} | X_i = \mathbf{x}_i) \\ &= \Phi(\beta_0 + \beta_1 x_{i1} + \dots + \beta_k x_{ik}). \end{aligned}$$

مدل رگرسیون پروبیت به صورت خلاصه:

$$Y_i = \begin{cases} 1, & Y_i^* > \theta \\ 0, & Y_i^* < \theta \end{cases}$$

$$Y_i | \mathbf{X}_i = \mathbf{x}_i \sim \text{Bernoulli}(\pi_i(\mathbf{x}_i)).$$

$$Y_i^* = \beta_1 x_{i1} + \cdots + \beta_k x_{ik} + \varepsilon_i,$$
$$\pi_i = \Phi(\beta_0 + \beta_1 x_{i1} + \cdots + \beta_k x_{ik}),$$

که در آن $\beta_0 = -\theta$.

تابع درستنمایی مدل پرویت

برای n مشاهده مستقل (y_i, x_i)

$$L(\boldsymbol{\beta}) = \prod_{i=1}^n \pi_i^{y_i} (1 - \pi_i)^{1-y_i},$$

که در آن

$$\pi_i = \Phi(-\theta + \beta_1 x_{i1} + \cdots + \beta_k x_{ik}).$$

ما با ماکزیمم کردن لگاریتم تابع درستنمایی l ، پارامترهای $\boldsymbol{\beta}$ و θ را برآورد می‌کنیم.

باز کردن داده‌ها در R و آماده‌سازی آن‌ها

مثال: بررسی پذیرش در مقطع تحصیلات تکمیلی

در این مجموعه داده، متغیرها به این صورت تعریف شده‌اند: آیا دانشجو در دوره تحصیلات تکمیلی پذیرفته شده است؟ (۰ = خیر، ۱ = بله)، نمره آزمون GRE، معدل مقطع قبلی و رتبه دانشگاه مقطع قبلی (از ۱ تا ۴؛ ۱ = بالاترین اعتبار، ۴ = کم‌ترین). هدف: برای پیش‌بینی احتمال «پذیرفته شدن» با استفاده از gre، gpa و rank.

```
> d = read.csv(
+   "E:\\1404-1405-1\\Math SoftWare\\datasets\\Universityadmission.csv"
+   header = TRUE
+ )
> head(d)
  admit gre  gpa rank
1     0 380 3.61    3
2     1 660 3.67    3
3     1 800 4.00    1
4     1 640 3.19    4
5     0 520 2.93    4
6     1 760 3.00    2
> attach(d)
> rank = factor(rank)
```

برازش در R با کمک تابع glm

```
> m = glm(admit~gre+gpa+rank ,family = binomial(link = "probit"))  
> m
```

```
Call: glm(formula = admit ~ gre + gpa + rank, family = binomial(link = "probit"))
```

```
Coefficients:
```

(Intercept)	gre	gpa	rank2	rank3	rank4
-2.386836	0.001376	0.477730	-0.415399	-0.812138	-0.935899

```
Degrees of Freedom: 399 Total (i.e. Null); 394 Residual
```

```
Null Deviance: 500
```

```
Residual Deviance: 458.4 AIC: 470.4
```

```
> |
```

$\pi_i =$

$$\Phi(-2.38 + 0.001 gre_i + 0.47 gpa_i - 0.4 rank2_i - 0.8 rank3_i - 0.9 rank4_i),$$

که در آن $i = 1, 2, \dots, 400$ و π_i پذیرش برای دانشجوی i ام است.

یافتن برآوردگرهای MLE

```
> rank2 = ifelse(rank==2,1,0)
> rank3 = ifelse(rank==3,1,0)
> rank4 = ifelse(rank==4,1,0)
> myprob <- function(p){
+ pi = pnorm(p[1]+p[2]*gre+p[3]*gpa+p[4]*rank2+p[5]*rank3+p[6]*rank4)
+ -sum(dbinom(admit,1,pi,log = TRUE))
+ }
> p0 = c(qnorm(mean(admit)),rep(0,5))
> nlminb(p0,myprob,lower = rep(-Inf,6),upper = rep(Inf,6))
$par
[1] -2.386839313  0.001375591  0.477730695 -0.415398788 -0.812137535
[6] -0.935898372

$objective
[1] 229.2066

$convergence
[1] 0

$iterations
[1] 13

$evaluations
function gradient
      27      99

$message
[1] "relative convergence (4)"
```

تفسیر پارامترها در رگرسیون پروبیت

- در رگرسیون پروبیت، هر ضریب نشان می‌دهد که افزایش یک متغیر، چگونه احتمال پذیرش را تغییر می‌دهد.
 - ضریب مثبت یعنی با زیاد شدن آن متغیر، احتمال پذیرش بالا می‌رود (مثل GRE و GPA)
 - ضریب منفی یعنی افزایش آن متغیر، احتمال پذیرش را کم می‌کند (مثل رتبه‌های ۲، ۳ و ۴ نسبت به رتبه ۱).
- نکته مهم:** اندازه ضرایب مستقیماً «میزان تغییر احتمال» را نشان نمی‌دهد؛ ضرایب فقط جهت و شدت اثر را بر یک نمره پنهان مشخص می‌کنند.

مقایسه دقت پیشگویی مدل لجستیک و پرویت در مثال قبل

```
> m1 = glm(admit~gre+gpa+factor(rank) ,family = binomial(link = "logit"))
> m2 = glm(admit~gre+gpa+factor(rank) ,family = binomial(link = "probit"))
> m1
```

```
Call: glm(formula = admit ~ gre + gpa + factor(rank), family = binomial(link = "logit"))
```

Coefficients:

(Intercept)	gre	gpa	factor(rank)2	factor(rank)3	factor(rank)4
-3.989979	0.002264	0.804038	-0.675443	-1.340204	-1.551464

Degrees of Freedom: 399 Total (i.e. Null); 394 Residual

~~Null Deviance: 500~~

Residual Deviance: 458.5 AIC: 470.5

```
> m2
```

```
Call: glm(formula = admit ~ gre + gpa + factor(rank), family = binomial(link = "probit"))
```

Coefficients:

(Intercept)	gre	gpa	factor(rank)2	factor(rank)3	factor(rank)4
-2.386836	0.001376	0.477730	-0.415399	-0.812138	-0.935899

Degrees of Freedom: 399 Total (i.e. Null); 394 Residual

~~Null Deviance: 500~~

Residual Deviance: 458.4 AIC: 470.4

مقایسه دقت پیشگویی مدل لجستیک و پروبیت در مثال قبل

$$\text{Residual Deviance} = -2 \ell(\hat{\beta}) \quad \text{AIC} = 2k - 2 \ell(\hat{\theta})$$

Residual Deviance فقط کیفیت برازش را می‌سنجد.
AIC برازش + پیچیدگی مدل را با هم می‌سنجد.

$$\text{Residual Deviance} = -2 \sum_{i=1}^n [y_i \log(\pi_i) + (1 - y_i) \log(1 - \pi_i)]$$

بنابراین بین چند مدل مختلف، مدلی که AIC کوچکتری دارد ترجیح داده می‌شود حتی اگر Residual Deviance کمی بزرگتر باشد، چون AIC از overfitting جلوگیری می‌کند.

```
> Yhat1 = ifelse(predict(m1, type = "response") > 0.5, 1, 0)
> Yhat2 = ifelse(predict(m2, type = "response") > 0.5, 1, 0)
> mean(Yhat1==admit)
[1] 0.71
> mean(Yhat2==admit)
[1] 0.71
```